## Московский государственный технический университет им. Н. Э. Баумана

Сурс «Технологии машинного обучения»	•>
Отчёт по лабораторной работе №4	

Выполнил:	Проверил:
Ювенский Л.А.	Гапанюк Ю.Е
группа ИУ5-63Б	

Дата: 14.03.25

Дата:

**Цель лабораторной работы:** изучение линейных моделей, SVM и деревьев решений.

## Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
  - а. одну из линейных моделей (линейную или полиномиальную регрессию при решении задачи регрессии, логистическую регрессию при решении задачи классификации);
  - b. SVM;
  - с. дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.
- 6. Постройте график, показывающий важность признаков в дереве решений.
- 7. Визуализируйте дерево решений или выведите правила дерева решений в текстовом виде.

## Ход выполнения:

```
↑ ↓ © ■ / 🖟 🗓 i
   Практика
    Датасет: https://github.com/ongaunjie1/credit-score-prediction

    Загрузка и первичный анализ

 [1] import numpy as np
import pandas as pd
import seaborn as nss
import matplotlib.pyplot as plt
*matplotlib inline
sns.set(style='ticks')

[2] df0 = pd.read_csv("/dataset.csv")

df0.info()

df0.head()

    age annual_income num_bank_acc num_credit_card interest_rate delay_from_due_date outstanding_debt credit_history_age installment_per_month monthly_balance payment_of_min_amount_Yes
        0 23 19114.12 3 4 3 3 809.98 22.90 49.57 186.27

    Разделение на обучающую и тестовую выборки

print("\n=====Y=
dfY.info()
dfY.head()
    =====X==
       <class 'pandas.core.series.Series'>
RangeIndex: 14790 entries, 0 to 14789
Series name: Predicted Credit Score
Non-Null Count Dtype
       14790 non-null int64
  <class 'pandas.core.series.Series'>
RangeIndex: 14790 entries, 0 to 14789
Series name: Predicted Credit Score
Non-Null Count Dtype
          14790 non-null int64
dtypes: int64(1)
memory usage: 115.7 KB
Predicted Credit Score
   / [5] from sklearn.model_selection import train_test_split
   ocs. [7] print(xTrain.shape)
print(xTest.shape)
print(yTrain.shape)
print(yTest.shape)
     ① (11832, 11)
(2958, 11)
(11832,)
(2958,)
```

-	Метрика / модель	Logistic Regression	SVM	Decision tree
	accuracy	0.675	0.67	0.888
	precision	0.666	0.603	0.888
	recall	0.675	0.67	0.888
	f1	0.638	0.629	0.888
			,	,

```
    График, показывающий важность признаков в дереве решений

✓ [25] import matplotlib.pyplot as plt
import numpy as np
/
[27] feature_importances = decision_tree_model.feature_importances_
        indices = np.argsort(feature_importances)[::-1]
          names = [dfX.columns[i] for i in indices]
         plt.figure()
plt.title("decision tree feature importances")
plt.barirange(dfX.shape[1]), feature_importances[indices])
plt.xticks(range(dfX.shape[1]), names, rotation=98)
plt.show()
    ₹
                                    decision tree feature importances
           0.35
           0.30
           0.25
           0.20
           0.15
           0.10
           0.05
                       rest_rate -
edit_card -
due_date -
nount_Yes -
s_month -
i_income -
story_age -
squ -
bank_acc -
```

##